



UNIVERSIDADE DO ESTADO DO AMAZONAS
ESCOLA SUPERIOR DE TECNOLOGIA

Alexandre do Valle Ferreira
Alice Sophia Lima Vieira
Pedro Yutaro Mont Morency Nakamura

AutoML

MANAUS – AMAZONAS
2026

SUMÁRIO

1. Parte 1 - O que é o AutoML?	3
2. Quais etapas de um projeto de Machine Learning podem ser automatizadas por ferramentas AutoML?	3
3. Quais etapas ainda dependem da análise humana?	4
4. Quais são as principais vantagens do AutoML?	4
5. Quais são os riscos ou limitações do uso de AutoML?	4
6. AutoML substitui o cientista de dados?	5
7. Parte 2 - Escolha do dataset	5

1. Parte 1 - O que é o AutoML?

AutoML significa "Aprendizado de Máquina Automatizado". Essa abordagem simplifica o pipeline de ciência de dados ao automatizar tarefas complexas como a escolha do algoritmo, o treinamento e a validação dos modelos. Embora muitas ferramentas ofereçam interfaces intuitivas que permitem a pessoas sem conhecimento técnico explorar o potencial da IA, o AutoML também é um aliado de especialistas, acelerando o desenvolvimento de soluções que vão desde o aprendizado de máquina tradicional até sistemas de deep learning.

2. Quais etapas de um projeto de Machine Learning podem ser automatizadas por ferramentas AutoML?

O AutoML consegue assumir quase todo o trabalho operacional e repetitivo do fluxo de desenvolvimento. As etapas que ele automatiza são:

- **Tratamento dos dados:** Realiza uma limpeza profunda e refinada nos dados que entram no sistema.
- **Engenharia de Recursos (Feature Engineering):** Descobre, seleciona e cria as variáveis mais importantes para o modelo de forma inteligente, além de preencher dados que estejam faltando.
- **Escolha e Treinamento do Modelo:** Testa diversos algoritmos ao mesmo tempo para ver qual performa melhor, inclusive combinando técnicas diferentes.
- **Ajuste de Hiperparâmetros:** Configura automaticamente as regras finas de aprendizado do modelo (o que exigiria muitas tentativas manuais).
- **Desenho de Redes Neurais (NAS):** Cria arquiteturas complexas de Deep Learning do zero de forma otimizada.
- **Testes e Validação:** Avalia o desempenho dos modelos e escolhe o campeão com base nos melhores resultados.
- **Publicação (Deployment):** Facilita a colocação do modelo em produção (em sites ou aplicativos), cuidando de atualizações e versões.

3. Quais etapas ainda dependem da análise humana?

A inteligência estratégica e o discernimento crítico continuam sendo totalmente humanos. Dependemos de pessoas para:

- **Preparação essencial dos dados:** A coleta inicial e a organização de uma base de dados limpa e sem preconceitos (vieses) devem ser feitas antes do AutoML agir.
- **Definição de objetivos:** Determinar o propósito do projeto e quais metas de negócio ou médicas (como evitar diagnósticos falsos) o modelo precisa priorizar.
- **Monitoramento e Controle:** Supervisionar o aprendizado para evitar que a máquina apenas decore os dados de treino, garantindo que ela funcione no mundo real.
- **Customização extrema:** Resolver problemas muito específicos onde as soluções automáticas padronizadas não se encaixam.

4. Quais são as principais vantagens do AutoML?

As ferramentas de AutoML trazem um impacto significativo para o desenvolvimento de projetos tecnológicos, destacando-se, primeiramente, pela sua velocidade. Essa tecnologia é capaz de transformar processos complexos de modelagem, que antes exigiam dias ou semanas de dedicação, em tarefas executadas em poucos minutos. Essa agilidade vem acompanhada de uma acentuada redução de falhas, uma vez que a automação diminui drasticamente a incidência de erros humanos na escrita de códigos e na definição de configurações críticas. Promove a acessibilidade e a democratização da área, permitindo que profissionais sem um conhecimento avançado em Inteligência Artificial consigam conceber e entregar soluções eficientes. Longe de ser uma alternativa simplista, a automação entrega modelos mais robustos, sendo capaz de testar e estruturar soluções combinadas de alta performance que seriam extremamente difíceis de se construir manualmente. Por fim, o processo preza pela transparência, ajudando a explicar de forma clara como as decisões dos modelos são tomadas e, consequentemente, gerando novos indicadores de valor estratégico para as empresas.

5. Quais são os riscos ou limitações do uso de AutoML?

Apesar de seus benefícios, a adoção do AutoML envolve desafios e limitações importantes que exigem atenção, a começar pelos seus custos invisíveis. O uso intensivo de poder de processamento para testar dezenas de modelos

simultaneamente pode elevar rapidamente o consumo de recursos computacionais, gerando gastos financeiros bastante elevados. Outro ponto crítico é o chamado efeito "Caixa-Preta", ou seja, o risco de a ferramenta conceber modelos com excelente desempenho matemático, mas cujo raciocínio interno e lógica de decisão são obtusos e difíceis de serem compreendidos ou explicados por seres humanos. Há o perigo, também, constante de overfitting, uma situação em que o modelo se torna perfeito ao analisar a base de dados de treinamento, mas falha totalmente ao lidar com situações reais e dados novos do dia a dia. Esse cenário é agravado pela perda de autonomia do desenvolvedor que, ao optar pela automação, acaba abrindo mão do controle detalhado e customizado sobre cada etapa de construção da solução. Por fim, o processo mantém uma estrita dependência da qualidade dos dados, o que significa que o AutoML não faz milagres: caso a base de dados inicial seja ruim ou enviesada, o sistema simplesmente gerará um modelo ruim de forma automatizada.

6. AutoML substitui o cientista de dados?

Não, o AutoML não substitui o cientista de dados. Na verdade, ele atua como um braço direito. Enquanto a ferramenta assume o trabalho mecânico e repetitivo de testes e códigos (o "como fazer"), o cientista de dados ganha tempo para focar na parte estratégica (o "por que fazer"). O profissional humano continua sendo indispensável para entender o problema de negócio, garantir a qualidade ética dos dados, monitorar os riscos de falha e traduzir os resultados da IA em decisões reais. O AutoML muda o papel do cientista de dados de "operário do código" para "arquiteto da solução".

7. Parte 2 - Escolha do dataset

O dataset escolhido para este projeto é o **Social Media and Teen Mental Health Dataset**, que está disponível na plataforma Kaggle, disponível em: <https://www.kaggle.com/datasets/algozee/teenager-menthal-healy/data>. O conjunto de dados possui 1200 registros e 13 atributos relacionados aos hábitos digitais, comportamento e saúde mental de adolescentes. A variável-alvo escolhida foi *stress_level*, representada por valores numéricos de 1 a 10, que indicam o nível de estresse do adolescente. O problema abordado é do tipo *regressão*, pois o objetivo é prever um valor numérico contínuo a partir das demais variáveis do dataset. A escolha desse conjunto de dados se justifica pela relevância do tema, considerando o impacto crescente das redes sociais e dos hábitos digitais na saúde mental dos jovens. Dessa forma, este dataset foi escolhido por permitir aplicar técnicas de regressão e AutoML em um contexto realista e atual, buscando analisar como fatores comportamentais podem influenciar os níveis de estresse dos adolescentes.

Atributos contidos:

1. age (idade) - variável numérica inteira.
2. gender (gênero) - variável categórica.
3. daily_social_media_hours (horas diárias nas redes sociais) - variável numérica contínua.
4. platform_usage (uso da plataforma) - variável categórica.
5. sleep_hours (horas de sono) - variável numérica contínua.
6. screen_time_before_sleep (tempo de tela antes de dormir) - variável numérica contínua.
7. academic_performance (desempenho acadêmico) - variável numérica contínua.
8. physical_activity (atividade física) - variável numérica contínua.
9. social_interaction_level (nível de interação social) - variável categórica ordinal.
10. stress_level (nível de estresse) - variável numérica inteira e variável-alvo do projeto.
11. anxiety_level (nível de ansiedade) - variável numérica inteira.
12. addiction_level (nível de dependência) - variável numérica inteira.
13. depression_label (indicador de depressão) - variável categórica/binária.