



UNIVERSIDADE ESTADUAL DO AMAZONAS  
ESCOLA SUPERIOR DE TECNOLOGIA  
CIÊNCIA DE DADOS - EQUIPE 6

Pedro Yutaro Mont Morency Nakamura  
Alexandre do Valle Ferreira  
Alice Sophia Lima Vieira

**Relatório de Execução - Atividade Prática de AutoML**

Manaus  
2026/05

## SUMÁRIO

|   |                                                       |   |
|---|-------------------------------------------------------|---|
| 1 | JUSTIFICATIVA DAS ALTERAÇÕES ARQUITETURAIS DO PROJETO | 5 |
| 2 | SOBRE A FERRAMENTA E SUA INSTALAÇÃO                   | 6 |
| 3 | PRINCIPAIS COMANDOS/ETAPAS UTILIZADAS                 | 7 |
| 4 | MODELOS TESTADOS E MELHOR MODELO                      | 8 |
| 5 | MÉTRICA PRINCIPAL OBTIDA E TEMPO DE EXECUÇÃO          | 9 |
| 6 | RECURSOS GERADOS PELA FERRAMENTA                      |   |

## JUSTIFICATIVA DAS ALTERAÇÕES ARQUITETURAIS DO PROJETO

### Problema Enfrentado:

Em relação à documentação inicial (Parte 1 e 2), a equipe precisou realizar alterações estruturais significativas no escopo do projeto de Machine Learning após as rodadas iniciais de Análise Exploratória de Dados (EDA). Originalmente, o projeto fora desenhado como uma tarefa de regressão para prever a variável contínua ***stress\_level***. Contudo, a análise da matriz de correlação de Pearson e a visualização de dispersão demonstraram uma ausência quase total de correlação linear entre os atributos preditores (como horas de sono e uso de redes sociais) e os níveis de estresse ou ansiedade. O treinamento de modelos sob essa configuração resultou em métricas de  $R^2$  negativas ou nulas, evidenciando que a tentativa de predição em uma escala contínua de 1 a 10 colapsava para a média, inviabilizando a extração de inteligência do modelo.

A solução proposta é a aplicação de questionários para mapear e categorizar os principais desafios lógicos percebidos pelos estudantes (por exemplo: laços, condicionais, abstração), com o objetivo de gerar um diagnóstico que possa embasar futuras intervenções pedagógicas e aprimorar a formação de novos profissionais na região.

### Solução:

Diante da ausência de sinal matemático forte para regressão, a equipe alterou a natureza do problema para Classificação Binária, elegendo o `depression_label` como a nova variável-alvo, alinhando-se ao objetivo geral do dataset de prever riscos à saúde mental. Para contornar o severo desbalanceamento de classes (onde casos positivos representavam cerca de 2,5% da base), foi aplicada a técnica de sobreamostragem SMOTE (Synthetic Minority Over-sampling Technique) exclusivamente no conjunto de treinamento.

Adicionalmente, para evitar o efeito "Dummy Classifier" — em que o modelo chuta a classe majoritária para minimizar o erro global devido ao limiar padrão de 50% de probabilidade —, a equipe implementou pesos de classe dinâmicos e uma técnica avançada de Threshold Tuning (Ajuste de Limiar). Isso permitiu focar a otimização no F1-Score da classe minoritária, garantindo um modelo funcional para triagem de risco.

## **SOBRE A FERRAMENTA E SUA INSTALAÇÃO**

Nome da Ferramenta: **FLAML** (*Fast and Lightweight AutoML*).

Sobre a ferramenta: Desenvolvida pela Microsoft Research, o FLAML é uma biblioteca open-source em Python projetada para automatizar o processo de seleção de modelos e otimização de hiperparâmetros (HPO) com alta eficiência. A ferramenta se destaca por encontrar modelos de alta acurácia com um custo computacional extremamente baixo, utilizando uma estratégia de busca heurística rápida e adaptativa em vez de buscar exaustivamente todas as combinações possíveis.

Processo de instalação e acesso: A ferramenta foi configurada e executada localmente em um ambiente Linux (CachyOS x86\_64). O gerenciamento de pacotes e a criação do ambiente virtual isolado foram realizados por meio da ferramenta **uv**. A instalação exigiu o comando **uv add flaml**, além da inclusão de bibliotecas auxiliares de ciência de dados e balanceamento (como **scikit-learn**, **pandas** e **imbalanced-learn**). O acesso e a execução ocorreram via Jupyter Notebook integrado ao ambiente virtual local.

## PRINCIPAIS COMANDOS/ETAPAS UTILIZADAS

O projeto foi estruturado utilizando o princípio de separação de responsabilidades em uma arquitetura baseada em camadas (Medallion-lite), refletida de forma fiel na organização dos diretórios (src/data/bronze, src/data/silver e src/notebooks). O fluxo de execução foi dividido em duas etapas principais:

### **Pré-processamento** (*01\_data-processing.ipynb*):

- Leitura do arquivo original mantido imutável na camada bronze.
- Encoding de variáveis categóricas para formato numérico inteiro (int), garantindo isonomia na leitura pelas ferramentas AutoML.
- Definição do alvo (depression\_label) e remoção das colunas stress\_level e anxiety\_level.
- Divisão estratificada dos dados em Treino (80%) e Teste (20%).
- Aplicação do algoritmo SMOTE exclusivamente no conjunto de Treino para balanceamento das classes.
- Exportação dos arquivos train.csv e test.csv estabilizados para a camada silver.

### **Treinamento e Otimização** (*02\_flaml-experiments.ipynb*):

- Importação dos dados da camada silver.
- Cálculo e aplicação de pesos dinâmicos (compute\_sample\_weight) para priorizar a classe minoritária.
- Instanciação do AutoML() configurado para: tarefa de classificação (task="classification"), métrica principal focada no F1-Score (metric="f1"), tempo de busca de 300 segundos, e validação cruzada estratificada (StratifiedKFold com 5 splits).
- **Ajuste Dinâmico de Limiar** (*Threshold Tuning*): Extração das probabilidades contínuas geradas pelo modelo (predict\_proba) e cálculo iterativo do ponto de corte exato que maximizasse a identificação da classe minoritária, substituindo o limiar padrão limitante de 0.50.

## MODELOS TESTADOS E MELHOR MODELO

A busca heurística do FLAML avaliou os seguintes estimadores (*estimators*):

1. **lgbm (LightGBM)**;
2. **xgboost**;
3. **catboost**;
4. **rf (Random Forest)**;
5. **sgd**;
6. **lgbm**;
7. **extra\_tree**;

### Melhor Modelo:

O estimador campeão, responsável pela melhor generalização do problema, foi o

**Random Forest (rf)**.

A configuração de hiperparâmetros otimizados eleita foi:

```
{  
'n_estimators': 278,  
'max_features': 0.1476803803449212,  
'max_leaves': 934,  
'criterion': 'entropy'  
}
```

## MÉTRICA PRINCIPAL OBTIDA E TEMPO DE EXECUÇÃO

### Métricas Obtidas:

A avaliação foi baseada no conjunto de teste isolado (dados reais e desbalanceados). Sob a métrica **ROC-AUC**, o modelo obteve **0.9028**. No entanto, a métrica mais relevante para o contexto clínico do problema foi o Recall alcançado após a técnica de Threshold Tuning (limiar otimizado de **0.1767**). A equipe priorizou a redução a zero dos Falsos Negativos, obtendo:

- **Recall (Classe 1):** 1.00 (identificou 100% dos alunos com depressão real no teste).
- **F1-Score Máximo Alcançado (Classe 1):** 0.2791.
- **Acurácia Global:** 0.87.

```
Limiar padrão do sistema: 0.5000
Novo Limiar Otimizado: 0.1767
F1-Score Máximo Alcançável (Classe 1): 0.2791

=== Novo Relatório de Classificação (Com Limiar Ajustado) ===
      precision    recall  f1-score   support

0         1.00      0.87      0.93        234
1         0.16      1.00      0.28          6

accuracy            0.87        240
macro avg          0.58      0.93      0.60        240
weighted avg       0.98      0.87      0.91        240
```

Figura 1 - Avaliação das Métricas do modelo usando o melhor Limiar obtido.

### Tempo aproximado de Execução:

O tempo de busca computacional (*Search Time*) para encontrar o melhor modelo e a melhor calibragem foi de apenas **0.33 segundos**.

```
Melhor modelo encontrado: rf

Hiperparâmetros otimizados:
{'n_estimators': 266, 'max_features': np.float64(0.17482732420788064), 'max_leaves': 934, 'criterion': np.str_('entropy')}


Tempo de busca (Search Time): 0.33 segundos
```

Figura 2 - Melhor modelo obtido, Hiperparâmetros otimizados e tempo de execução.

## RECURSOS GERADOS PELA FERRAMENTA


A execução e a implementação geraram os seguintes artefatos para análise:

**1 - Logs de Execução:** Histórico completo de treinamento salvo no diretório `src/logs/flaml/flaml_clf_balanced.log`.



*Figura 3 - Logs de execução do FlaML.*

**2 - Ranking de Importância de Atributos (Feature Importance):** Gráfico listando o impacto de cada variável nas decisões do modelo (destacando horas de sono e uso diário de redes sociais como os principais preditores).



*Figura 4 - Ranking das features mais importantes.*



**3 - Gráfico de Otimização de Limiar:** Curva visual demonstrando a flutuação do F1-Score de acordo com os diferentes limiares de decisão possíveis.




Figura 5 - Otimização do Limiar em função do F1-Score da classe 1.

**4 - Matrizes de Confusão:** Representações visuais do desempenho do modelo antes e depois do ajuste de limiar, evidenciando o sacrifício estratégico da Precisão (aumento de Falsos Positivos) em favor de um Recall perfeito (eliminação de Falsos Negativos).




Figura 6 - Matriz de Confusão do modelo usando o melhor Limiar obtido.

## ATRIBUTOS DO DATASET E EVIDÊNCIAS:

### Nova Configuração de atributos:

Os atributos extraídos para as ferramentas de automl se dão por:

1. **age (idade)** - variável numérica inteira.
2. **gender (gênero)** - variável categórica numérica (0 = male; 1 = female).
3. **daily\_social\_media\_hours (horas diárias nas redes sociais)** - variável numérica contínua.
4. **platform\_usage (uso da plataforma)** - variável categórica numérica.
5. **sleep\_hours (horas de sono)** - variável numérica contínua.
6. **screen\_time\_before\_sleep (tempo de tela antes de dormir)** - variável numérica contínua.
7. **academic\_performance (desempenho acadêmico)** - variável numérica contínua.
8. **physical\_activity (atividade física)** - variável numérica contínua.
9. **social\_interaction\_level (nível de interação social)** - variável categórica numérica (low = 0, medium = 1, high = 2).
10. **addiction\_level (nível de dependência)** - variável numérica inteira.
11. **depression\_label (indicador de depressão)** - variável categórica/binária (TARGET).

### GitHub do Projeto:

[https://github.com/PedroYutaroUEA/depression-prediction\\_autoML](https://github.com/PedroYutaroUEA/depression-prediction_autoML)