



UNIVERSIDADE ESTADUAL DO AMAZONAS
ESCOLA SUPERIOR DE TECNOLOGIA
CIÊNCIA DE DADOS - EQUIPE 6

Pedro Yutaro Mont Morency Nakamura
Alexandre do Valle Ferreira
Alice Sophia Lima Vieira

Relatório de Execução - Atividade Prática de AutoML (Segunda Ferramenta)

Manaus
2026/05

SUMÁRIO

1	QUAL FOI A FERRAMENTA	5
2	SOBRE A FERRAMENTA E SUA INSTALAÇÃO	6
3	PRINCIPAIS COMANDOS/ETAPAS UTILIZADAS	7
4	MODELOS TESTADOS E MELHOR MODELO	8
5	MÉTRICA PRINCIPAL OBTIDA E TEMPO DE EXECUÇÃO	9
6	RECURSOS GERADOS PELA FERRAMENTA	

JUSTIFICATIVA DAS ALTERAÇÕES ARQUITETURAIS DO PROJETO

Problema Enfrentado:

Em relação à documentação inicial (Partes 1 e 2), a equipe precisou realizar alterações estruturais significativas no escopo do projeto de Machine Learning após as rodadas iniciais de Análise Exploratória de Dados (EDA). Originalmente, o projeto fora desenhado como uma tarefa de regressão para prever a variável contínua ***stress_level***. Contudo, a análise da matriz de correlação de Pearson e a visualização de dispersão demonstraram uma ausência quase total de correlação linear entre os atributos preditores (como horas de sono e uso de redes sociais) e os níveis de estresse ou ansiedade. O treinamento de modelos sob essa configuração resultou em métricas de R^2 negativas ou nulas, evidenciando que a tentativa de predição em uma escala contínua de 1 a 10 colapsava para a média, inviabilizando a extração de inteligência do modelo.

A solução proposta é a aplicação de questionários para mapear e categorizar os principais desafios lógicos percebidos pelos estudantes (por exemplo: laços, condicionais, abstração), com o objetivo de gerar um diagnóstico que possa embasar futuras intervenções pedagógicas e aprimorar a formação de novos profissionais na região.

Solução:

Diante da ausência de sinal matemático forte para regressão, a equipe alterou a natureza do problema para Classificação Binária, elegendo o `depression_label` como a nova variável-alvo, alinhando-se ao objetivo geral do dataset de prever riscos à saúde mental. Para contornar o severo desbalanceamento de classes (onde casos positivos representavam cerca de 2,5% da base), foi aplicada a técnica de sobreamostragem SMOTE (Synthetic Minority Over-sampling Technique) exclusivamente no conjunto de treinamento.

Adicionalmente, para evitar o efeito "Dummy Classifier" — em que o modelo chuta a classe majoritária para minimizar o erro global devido ao limiar padrão de 50% de probabilidade —, a equipe implementou pesos de classe dinâmicos e uma técnica avançada de Threshold Tuning (Ajuste de Limiar). Isso permitiu focar a otimização no F1-Score da classe minoritária, garantindo um modelo funcional para triagem de risco.

SOBRE A FERRAMENTA E SUA INSTALAÇÃO

Nome da Ferramenta: MLJAR (*mljar-supervised*).

Sobre a ferramenta: O MLJAR é uma biblioteca avançada de AutoML com um forte direcionamento para a Inteligência Artificial Explicável (XAI - Explainable AI). Ao contrário de soluções que operam como "caixas pretas", o MLJAR automatiza não apenas o treinamento e a otimização de hiperparâmetros, mas também a Análise Exploratória de Dados (EDA) e a documentação. A ferramenta constrói Ensembles (combinações de múltiplos modelos) nativamente e gera relatórios automáticos em Markdown e HTML detalhando o funcionamento interno de cada algoritmo testado.

Processo de instalação e acesso: A instalação seguiu o padrão arquitetural do projeto, sendo realizada no ambiente virtual local isolado através do gerenciador de pacotes uv. O comando utilizado via interface de linha de comando (CLI) foi ***uv add mljar-supervised***.

PRINCIPAIS COMANDOS/ETAPAS UTILIZADAS

A aplicação do MLJAR utilizou a mesma estrutura de dados lapidada na camada Silver, garantindo isonomia na comparação com o FLAML. As etapas englobaram:

Treinamento e Otimização (*03_mljar-experiments.ipynb*):

- **Carregamento dos Dados:** Importação do conjunto de Treino (previamente balanceado em 50/50 com a técnica SMOTE) e do conjunto de Teste (mantido com a distribuição original e desbalanceada do mundo real).
- **Configuração do AutoML:** Instanciação da classe AutoML() configurada no modo "**Perform**" (focado em criar modelos robustos para produção). A métrica de avaliação interna (**eval_metric**) foi definida como "f1", com um tempo limite total (**total_time_limit**) de 300 segundos.
- **Estratégia de Validação:** Foi aplicada uma validação cruzada k-fold estratificada de 5 partições ($k = 5$), garantindo que a proporção das classes fosse respeitada em cada subdivisão do treino.
- **Execução do Pipeline:** O MLJAR executou etapas automatizadas sequenciais, incluindo: algoritmos padrão, inserção de características douradas (**golden_features**), seleção de características (**features_selection**), **Hill Climbing** para otimização fina e, por fim, a construção do Ensemble.
- **Ajuste Dinâmico de Limiar (Threshold Tuning):** Assim como feito no FLAML, a predição binária padrão foi substituída pela extração de probabilidades (**predict_proba**). A curva Precision-Recall foi calculada no conjunto de teste para encontrar o ponto de corte ideal que maximizasse a captura da classe minoritária.

MODELOS TESTADOS E MELHOR MODELO

Durante o seu tempo de execução, o MLJAR avaliou mais de 36 configurações diferentes (como evidenciado pela matriz de correlação gerada) em seu Pipeline de execução, aplicando heurísticas em diferentes etapas (como **default_algorithms** e **not_so_random**), testando variações de algoritmos baseados em **decision-tree**:

1. **lgbm** (LightGBM);
2. **xgboost**;
3. **catboost**;
4. **rf** (Random Forest);

Ao final do processo, a ferramenta construiu automaticamente um modelo combinado (Ensemble) utilizando as melhores previsões dos algoritmos individuais.

Melhor Modelo:

Embora o modelo Ensemble tenha obtido a maior pontuação combinada no treinamento, o melhor modelo isolado construído pela ferramenta (Top 1 no Leaderboard) foi o **LightGBM** com hiperparâmetros padrão (**1_Default_LightGBM**).




Figura 1 - Performance dos modelos testados em razão das iterações.

MÉTRICA PRINCIPAL OBTIDA E TEMPO DE EXECUÇÃO

Métricas Obtidas:

A avaliação foi realizada sob as métricas do conjunto de teste (dados invisíveis e desbalanceados). A métrica principal otimizada, **ROC-AUC**, alcançou **0,9274** (superando o FLAML). Após a aplicação do **Threshold Tuning**, o limiar de decisão ótimo foi reduzido de **0,50** para **0,0833**. Com este ajuste com foco na sensibilidade clínica, o modelo obteve:

- **Recall (Classe 1):** 1,00 (taxa de acerto de 100% sobre os casos reais de depressão).
- **F1-Score Máximo Alcançado (Classe 1):** 0,3333.
- **Falsos Positivos:** 24 (*Nota: Ao priorizar o recall perfeito, o MLJAR produziu 7 Falsos Positivos a menos, apresentando uma fronteira de decisão mais limpa e eficiente que a primeira ferramenta avaliada*).
- **Acurácia Global:** 0,90.

```
=== Desempenho no Conjunto de Teste ===
Métrica Otimizada (ROC-AUC): 0.9274
Acurácia Global: 0.9000
=== Novo Relatório de Classificação ===
```

	precision	recall	f1-score	support
0	1.00	0.90	0.95	234
1	0.20	1.00	0.33	6
accuracy			0.90	240
macro avg	0.60	0.95	0.64	240
weighted avg	0.98	0.90	0.93	240

Figura 2 - Avaliação das métricas do modelo com o melhor Linear obtido.

Tempo aproximado de execução:

Devido à sua busca exaustiva por validações cruzadas, criação de características sintéticas (*golden features*) e elaboração do *Ensemble*, o tempo total de ajuste (*AutoML fit time*) foi de **308,05 segundos** (aproximadamente 5 minutos), utilizando quase a totalidade do orçamento de tempo concedido.

```
Ensemble f1 0.98314 trained in 4.39 seconds (1-sample predict time 0.0173 seconds)
AutoML fit time: 308.05 seconds
AutoML best model: 22_LightGBM
Treinamento Finalizado!
```

Figura 3 - Tempo de execução total e melhor modelo obtido.

RECURSOS GERADOS PELA FERRAMENTA

O MLJAR destacou-se pela vasta geração automática de artefatos de Explicabilidade (**XAI**) salvos em disco no diretório **logs/mljar**. A ferramenta populou o diretório com os diversos recursos voltados a resultados gerais e específicos:

1 - Visão Global do Experimento: O diretório raiz gerou um painel de controle contendo o ranking de modelos (**leaderboard.csv**), boxplots de performance, correlação de Spearman entre as predições dos modelos (**OOF Predictions**), matrizes em escala de calor (**features_heatmap_scaled.png**) e arquivos JSON registrando cada hiperparâmetro utilizado.




Figura 4 - Boxplot de performance dos modelos testados em razão do F1-score.

2 - Visão Detalhada do Modelo Vencedor (1_Default_LightGBM): Para o modelo campeão, a ferramenta gerou 29 arquivos exclusivos, incluindo: Curvas ROC (**roc_curve.png**), Curvas de Precisão-Recall (**precision_recall_curve.png**), Matrizes de Confusão absolutas e normalizadas, Curvas de Aprendizado e relatórios em Markdown detalhando o comportamento do algoritmo.




Figura 5 - Curvas de Precisão-Recall das duas classes do modelo vencedor.




Figura 6 - Curvas de aprendizado do modelo vencedor para cada partição de treino/teste.




Figura 7 - Matriz de Confusão normalizada do modelo vencedor.

Dentre os principais recursos-chave extraídos gerais e específicos, destacam-se:

1 - Leaderboard Top 10: Um arquivo CSV resumizando o ranking dos modelos testados e avaliados.

	name	model_type	metric_type	metric_value	train_time	single_prediction_time
0	1_Default_LightGBM	LightGBM	f1	0.978925	12.33	0.0158
1	2_Default_Xgboost	Xgboost	f1	0.978523	14.40	0.0178
2	3_Default_CatBoost	CatBoost	f1	0.978523	4.13	0.0176
3	4_Default_RandomForest	Random Forest	f1	0.950051	6.02	0.0796
4	9_LightGBM	LightGBM	f1	0.982622	7.82	0.0168
5	5_Xgboost	Xgboost	f1	0.978478	6.04	0.0183
6	13_CatBoost	CatBoost	f1	0.976987	4.52	0.0182
7	17_RandomForest	Random Forest	f1	0.957732	6.20	0.0788
8	10_LightGBM	LightGBM	f1	0.978992	6.04	0.0171
9	6_Xgboost	Xgboost	f1	0.947906	5.44	0.0174
10	14_CatBoost	CatBoost	f1	0.979014	4.42	0.0206

Figura 8 - Top 10 melhores modelos obtidos pelo MLJAR.

2 - Ranking de Importância de Atributos: Gráfico de calor dimensionado (MinMax), permutação de importância de features e tabelas “.csv” apontando decisivamente que as horas de sono (**sleep_hours** com importância média de 0,82) e o uso diário de redes sociais (**daily_social_media_hours** com 0,81) foram os maiores responsáveis matemáticos pelas predições do modelo LightGBM.




Figura 9 - Ranking das permutações de features mais importantes.

3 - Spearman Correlation of Models' OOF Predictions: Um mapa de calor de correlação cruzada demonstrando como as previsões de cada uma das dezenas de modelos testados se comportavam em relação aos outros (Out-of-Fold).




Figura 10 - Mapa de calor de previsões OOF entre os modelos testados.

4 - Curvas ROC (ROC Curves): Gráficos nativos mostrando a Área Sob a Curva para cada classe durante o treinamento.




Figura 11 - Curva ROC das duas classes do melhor modelo (LightGBM).

5 - Curva de Variação do Limiar e Matriz de Confusão Otimizada: Gráficos plotados pela equipe evidenciando a queda do limiar para 0,08 e a matriz final que atesta a eficácia da triagem clínica (0 Falsos Negativos).




Figura 12 - Otimização do Limiar em função do F1-Score da classe 1.




Figura 13 - Matriz de Confusão do modelo com o melhor linear obtido.

ATRIBUTOS DO DATASET E EVIDÊNCIAS:

Nova Configuração de atributos:

Os atributos extraídos para as ferramentas de automl se dão por:

1. **age (idade)** - variável numérica inteira.
2. **gender (gênero)** - variável categórica numérica (0 = male; 1 = female).
3. **daily_social_media_hours (horas diárias nas redes sociais)** - variável numérica contínua.
4. **platform_usage (uso da plataforma)** - variável categórica numérica.
5. **sleep_hours (horas de sono)** - variável numérica contínua.
6. **screen_time_before_sleep (tempo de tela antes de dormir)** - variável numérica contínua.
7. **academic_performance (desempenho acadêmico)** - variável numérica contínua.
8. **physical_activity (atividade física)** - variável numérica contínua.
9. **social_interaction_level (nível de interação social)** - variável categórica numérica (low = 0, medium = 1, high = 2).
10. **addiction_level (nível de dependência)** - variável numérica inteira.
11. **depression_label (indicador de depressão)** - variável categórica/binária (TARGET).

GitHub do Projeto:

https://github.com/PedroYutaroUEA/depression-prediction_autoML